期末考试最后一节课资料

（个别老师课上有，请同学们期末复习时不同班别相互共享一下复习资料）

计算机体系结构基础试题

一、填空题

1. 计算机系统中提高并行性的主要途径有时间重叠、资源共享、资源重复。
2. 指令之间的名相关有反相关和输出相关两种。
3. 说出两种比较典型的动态调度算法：记分牌和 Tomasulo。

二、简答题

1. 记分牌算法中，记分牌中记录的信息由哪 3 部分构成？

答案：
指令状态表：记录正在执行的各条指令已经进入到了哪一段。
功能部件状态表：记录各个功能部件的状态。每个功能部件有一项，每一项由 9 个字段组成。
结果寄存器状态表 Result：每个寄存器在该表中有一项，用于指出哪个功能部件（编号）将把结果写入该寄存器。

三、解答题

1. 找出下面程序中的相关关系，给出相关程序对及其相关类型。采用寄存器换名的方法消除程序中的名相关，给出修改后的代码。

行号	指令	操作数
0:	L.D	F0, 100(R1)
1:	ADD.D	F2, F0, F3
2:	MUL.D	F5, F0, F6
3:	S.D	F2, 100(R1)
4:	ADD.D	F6, F3, F10
5:	SUB.D	F8, F6, F3

填空题 / 简答题参考答案

〔原图转录〕

- 并行计算机硬件分类 Flynn 分类法分成 4 类：
  SISD（Single Instruction Single Data）
  SIMD（Single Instruction Multiple Data）
  MISD（Multiple Instruction Single Data）
  MIMD（Multiple Instruction Multiple Data）
- 常见的 AI 处理器有哪些？如 GPU、TPU、华为昇腾、寒武纪等。
- 英伟达的 GPU 存储器有哪些？包括寄存器、共享存储器、L1 缓存、L2 缓存和全局存储器。
- 共享存储器是在哪个级别的线程共享的？Block 级别。
- 英伟达 GPU 中，一个 Warp 通常有多少线程？32。
- 现代 AI 处理器（如英伟达的 H100、Google TPU）以什么执行单元提供算力？矩阵乘法单元或 Tensor Core。

GPU Kernel 索引计算

给定 GPU Kernel 的 Grid 和 Block 配置以及计算任务的分配，用 blockDim、blockIdx 和 threadIdx 算出索引，如下图。

答案：

```
__global__ void MatMulKernel(float* Md, float* Nd, float* Pd, int Width)
{
    // Calculate the row index of the P element and M
    int Row = blockIdx.y*blockDim.y + threadIdx.y;
    // Calculate the column index of the P element and N
    int Col = blockIdx.x*blockDim.x + threadIdx.x;

    if ( (Row < Width) && (Col < Width) ) {
        float Pvalue = 0.0;
        // each thread computes one element of the block sub-matrix
        for (int k = 0; k < Width; ++k)
            Pvalue += Md[Row*Width+k] * Nd[k*Width+Col];
        Pd[Row*Width+Col] = Pvalue;
    }
}
```

自动驾驶计算

假设一辆自动驾驶汽车在高速公路上以 120 km/h 的速度行驶，车辆装备有多个摄像头和雷达传感器。数据处理和 AI 模型推理由一块性能为 2 TFLOPS（Tera Floating Point Operation Per Second）的 GPU 完成。

假设 AI 模型的计算量为 140 GFLOPs（Giga Floating Point Operations）。

感知模块除模型推理外，其余数据处理计算 0.03 s。

规划模块的工作周期是 0.1 s，控制模块的工作周期是 0.01 s。

a) 在给定的硬件条件下，AI 模型完成一次完整数据处理的时间是多少？

b) 考虑到感知、规划、控制的整体工作流，各模块采用定时器触发工作与由上游消息实时触发工作两种模式，最坏情况下的总反应时间分别是多少？

c) 基于以上计算，分别估算两种工作模式下，当 80 m 外突然出现障碍物时，汽车能否成功制动。（120 km/h 的制动距离为 70 m）

答案：

a) AI 模型数据处理时间：

AI 模型计算量 140 GFLOPs = 0.14 TFLOPs（因为 1 TFLOPs = 1000 GFLOPs）

GPU 性能：2 TFLOPS

计算时间 = AI 模型计算量 / GPU 性能

= 0.14 TFLOPs / 2 TFLOPS

= 0.07 s

b) 总的反应时间：

定时器触发（最坏情况下需要等待一个周期）：

AI 模型数据处理时间：0.07 s

感知：0.03 s

规划：10 Hz

控制：100 Hz

= 0.1 s（传感器数据等待上一轮感知模型推理以及数据计算） + 0.07 s（模型推理） + 0.03 s（感知数据计算） + 0.1 s（等待规划一个周期） + 0.1 s（规划工作）

（原截图至此为止，未包含 c）小题的答案。）

2023 级-计算机体系结构-回忆版

大致与上述内容题型相同，有改编题也有原题也有新题。

By zyj ,zjc，自救群友

一、填空题（20 分）

〔原图转录〕（原图中贴在填空题处的答案要点）

- 计算机系统中提高并行性的主要途径有时间重叠、资源共享、资源重复。
- 指令之间的名相关有反相关和输出相关两种。
- 说出两种比较典型的动态调度算法：记分牌和 Tomasulo。
- 常见的 AI 处理器有哪些？如 GPU、TPU、华为昇腾、寒武纪等。
- 英伟达的 GPU 存储器有哪些？包括寄存器、共享存储器、L1 缓存、L2 缓存和全局存储器。
- 共享存储器是在哪个级别的线程共享的？Block 级别。
- 英伟达 GPU 中，一个 Warp 通常有多少线程？32。

1. 自动驾驶常用的传感器有哪些：_____，_____，_____。

二、简答题（30 分）

1. Flynn 并行计算机硬件分类（5 分）

〔原图转录〕

- 并行计算机硬件分类 Flynn 分类法分成 4 类：
  SISD（Single Instruction Single Data）
  SIMD（Single Instruction Multiple Data）
  MISD（Multiple Instruction Single Data）
  MIMD（Multiple Instruction Multiple Data）

2. 英伟达的 GPU 存储器有哪些？（请 gpu 的各个存储层次的部件）（5 分）

3. 给定 GPU Kernel 的 Grid 和 Block 配置以及计算任务，请补充以下代码（注：题目只有这么多信息，与样题不同）（10 分）

```
__global__ void MatMulKernel(float* Md, float* Nd, float* Pd, int Width)
{
    // Calculate the row index of the P element and M
    int Row = _____;
    // Calculate the column index of the P element and N
    int Col = _____;
    if ( (Row < Width) && (Col < Width) ) {
        float Pvalue = 0.0;
        // each thread computes one element of the block sub-matrix
        for (int k = 0; k < Width; ++k)
            Pvalue += Md[_____] * Nd[_____];
        Pd[_____] = Pvalue;
    }
}
```

（二、简答题　续）

4. 指令调度信息表（会提供表格，挖空填写）（10 分）

〔原图转录〕

对于下述指令序列，给出当第一条指令完成并写入结果时，Tomasulo 算法所用的各信息表中的内容。

行号	指令	操作数
0:	L.D	F6, 34 (R2)
1:	L.D	F2, 45 (R3)
2:	MUL.D	F0, F2, F4
3:	SUB.D	F8, F2, F6
4:	DIV.D	F10, F0, F6
5:	ADD.D	F6, F8, F2

当采用 Tomasulo 算法时，在上述给定的时刻，保留站、load 缓冲器以及寄存器状态表中的内容。

指　令	指令状态表		
	流出	执行	写结果
L.D　F6, 34(R2)	√	√	√
L.D　F2, 45(R3)	√	√	
MUL.D　F0, F2, F4	√		
SUB.D　F8, F6, F2	√		
DIV.D　F10, F0, F6	√		
ADD.D　F6, F8, F2	√		

名称	保留站						
	Busy	Op	Vj	Vk	Qj	Qk	A
Load1	no						
Load2	yes	LD					45+Regs[R3]
Add1	yes	SUB		Mem[34+Regs[R2]]	Load2		
Add2	yes	ADD			Add1	Load2	
Add3	no						
Mult1	yes	MUL		Reg[F4]	Load2		
Mult2	yes	DIV		Mem[34+Regs[R2]]	Mult1		

	寄存器状态表							
	F0	F2	F4	F6	F8	F10	…	F30
Qi	Mult1	Load2		Add2	Add1	Mult2	…	

（注：原件指令序列中 SUB.D 写作「F8, F2, F6」，而指令状态表中写作「F8, F6, F2」，此处按各自原图保留。）

三、解答题

1. 请描述评估分支预测有效性的指标（10 分）
2. 请画图描述分支预测器在取指、译码、执行阶段做了哪些工作（10 分）
3. 自动驾驶当中用到了哪些传感器及其功能？（10 分）
4. 指令相关和调度（8 分）

〔原图转录〕
找出下面程序中的相关关系，给出相关程序对及其相关类型。采用寄存器换名的方法消除程序中的名相关，给出修改后的代码。

行号	指令	操作数
0:	L.D	F0, 100(R1)
1:	ADD.D	F2, F0, F3
2:	MUL.D	F5, F0, F6
3:	S.D	F2, 100(R1)
4:	ADD.D	F6, F3, F10
5:	SUB.D	F8, F6, F3

5. 自动驾驶计算原题（12 分）

〔原图转录〕〔参考答案见「自动驾驶计算」一节〕
假设一辆自动驾驶汽车在高速公路上以 120 km/h 的速度行驶，车辆装备有多个摄像头和雷达传感器。数据处理和 AI 模型推理由一块性能为 2 TFLOPS（Tera Floating Point Operation Per Second）的 GPU 完成。
假设 AI 模型的计算量为 140 GFLOPs（Giga Floating Point Operations）。
感知模块除模型推理外，其余数据处理计算 0.03 s。
规划模块的工作周期是 0.1 s，控制模块的工作周期是 0.01 s。

a) 在给定的硬件条件下，AI 模型完成一次完整数据处理的时间是多少？
b) 考虑到感知、规划、控制的整体工作流，各模块采用定时器触发工作与由上游消息实时触发工作两种模式，最坏情况下的总反应时间分别是多少？
c) 基于以上计算，分别估算两种工作模式下，当 80 m 外突然出现障碍物时，汽车能否成功制动。（120 km/h 的制动距离为 70 m）